Дисциплина: Проектирование систем машинного обучения
Задание 3: Умный ритейл - Тепловая карта движения покупателей в супермаркете
Группа: М8О-214СВ-24
Студент: Прудникова Анастасия Алексеевна
11 декабря 2025

Часть 1: Формулировка ML-задачи

1.1 Бизнес-цели и ключевые метрики

Бизнес-цели:

- Повысить эффективность размещения товаров и планограммы магазина.
- Уменьшить потери от неоптимальной выкладки (корректировка зон горячего/холодного трафика).
- Обеспечить приватность клиентов при сборе аналитики.

Ключевые бизнес-метрики (KPI):

1. Conversion lift в целевых зонах (%) - процентное увеличение продаж в зонах, оптимизированных по тепловой карте. Цель: +3–8% через 3 месяца после внедрения.
2. Снижение времени простоя персонала (мин/день) - оптимизация расстановки персонала по трафику; метрика измеряется через сравнение планируемых и фактических затраченных часов.
3. Соблюдение конфиденциальности (%) - доля видео/изображений, где лица размыты/анонимизированы. Цель: 100%.

1.2 Постановка ML-задачи

Формулировка: задача состоит из двух взаимосвязанных подзадач:

1. Обнаружение людей и локализация (object detection) - выдача масок людей на каждом кадре. (задача детекции/сегментации).
2. Трекинг и агрегация траекторий (multi-object tracking + aggregation) - присвоение ID траекториям, агрегация позиций в пространственную сетку (heatmap). (детекция + ассоциация/ранжирование => последовательные события).

Типы задач:

- Детекция - классификация + локализация, object detection.
- Трекинг - последовательное сопоставление (tracking/association/ranking).
- Пост-обработка для тепловой карты - агрегация по ячейкам сетки.

Целевая переменная:

- Для детекции - наличие человека и его координаты (bounding box/mask).
- Для трекинга - ID траектории (association keys).

- Для тепловой карты - количество уникальных «присутствий» или средняя длительность пребывания в каждой ячейке за заданный интервал.

1.3 Данные для обучения и валидации

Необходимые данные:

- Видео с камер супермаркета (разрешение/фреймрейт, разные углы обзора, освещение).
- Аннотированные кадры: bounding boxes людей, маски сегментации.
- Аннотации для трекинга: идентификаторы объектов в последовательностях кадров (для обучения ассоциации/ре-идентификации).
- Метаданные камер: расположение камеры в плане магазина, параметры проекции (H/FOV).
- POS-данные для сопоставления тепловых зон с продажами для бизнес-метрик.
- Анонимизированные примеры с размытыми лицами для проверки приватности.

Количество данных:

- ~50–200 тысяч аннотированных кадров для надежной детекции в пределах супермаркета
- ~200–1000 коротких видео-последовательностей (30–300 кадров) с ID для обучения трекинга

1.4 Выбор моделей - минимум две опции

Модель A: YOLOv8 (детекция) + DeepSORT (трекинг)

Преимущества:

- Высокая скорость инференса на GPU/Edge; подходит для реального времени.
- Широкая экосистема и легкая интеграция.
- DeepSORT даёт простую и быструю ассоциацию на основе appearance+motion.

Недостатки:

- DeepSORT может деградировать при плотных сценах/длинных occlusions без дообученной re-id модели.
- YOLO иногда уступает по точности современным трансформерным моделям на рынках с сложным фоном.

Модель B: EfficientDet / CenterNet + FairMOT (или byteTrack)

Преимущества:

- FairMOT совмещает детекцию и трекинг в единой сети - лучшее качество ассоциации при плотном трафике.
- EfficientDet даёт неплохой компромисс точности и скорости на CPU/GPU, если требуется экономичный inference.

Недостатки:

- Более высокая сложность внедрения и тонкая настройка.
- Меньшее сообщество и референтная реализация по сравнению с YOLO.

Выбор для дальнейшего проектирования: YOLOv8 + DeepSORT.

Обоснование выбора: YOLOv8 + DeepSORT даёт наилучший стартовый компромисс между скоростью, простотой и точностью для бизнес-целей. Можно добавить дообучение re-id и использовать ByteTrack/FairMOT как опциональную компоненту при росте требований к качеству трекинга.

Часть 2: Проектирование архитектуры

2.1 Высокоуровневая архитектура системы

Ключевые компоненты:

- Камеры (Edge) - локальная обработка: детекция лиц => размытие (анонимизация) => сжатие.
- Edge Inference Nodes - быстрый детектор + локальный трекинг (опция) для уменьшения трафика.
- Stream Broker (Kafka/Kinesis) - передача анонимизированных событий (bounding boxes, траектории) и метрик.
- Real-time Analytics (Flink/Beam or ksqlDB) - агрегация по сетке (heatmap), оконная агрегация.
- Feature Store/Time Series DB (InfluxDB, Timescale) - хранение агрегированных тепловых карт.
- Object Storage (S3) - хранение анонимизированных кадров/мини-видео для отладки и ретроспективного обучения (ср. ретеншен 7–30 дней).
- Model Training Cluster (K8s + GPU nodes) - обучение/дообучение моделей.
- Serving Layer (K8s Horizontal Autoscaling + GPU/CPU instances) - REST/gRPC endpoint для модели (batch & streaming).
- API Gateway/CDN - внешние запросы дашбордов/мобильных приложений.
- Monitoring & Privacy Auditor - проверка размывания лиц и задержек.

2.2 Архитектура Data Pipeline

Поток данных:

1. Камеры => Edge preprocessing (denoise, resize, face blur).
2. Анонимизированный поток (кадры или ключевые фичи) публикуется в Stream Broker.
3. Stream Consumers (Edge/Cloud) выполняют детекцию/трекинг и отправляют события: `{timestamp, store_id, cam_id, x,y,track_id,confidence}`.
4. Real-time Aggregator делает spatial binning (grid) => incremental heatmap updates.
5. Хранение агрегатов в TSDB + snapshot в object storage.

Privacy step: размытие лиц на Edge или первичном cloud-узле (ниже 1-ms дополнительного latency per frame на edge)

2.3 Архитектура Training Pipeline

Основные шаги:

- Data Ingestion: выбор аннотированных кадров/последовательностей из object storage.

- Data Augmentation: имитация разных освещений, поворотов камер, occlusion, synthetic blur.
- Training: distributed training на GPU (PyTorch, DDP).
- Validation & Metrics: mAP для детекции, MOTA/MOTP для трекинга, latency profiling.
- Model Registry (MLflow/Triton Model Repository): версии моделей, артефакты, метаданные.
- CI/CD: автоматическое тестирование качества и canary deploy для serving.

2.4 Архитектура Inference Pipeline (Serving)

Стратегии сервинга:

- Edge first: простое детектирование + blur выполняется максимально на edge (Raspberry/Jetson/Intel NUC), лишь события стримятся.
- Hybrid cloud: тяжёлая модель (повышенной точности) может работать в облаке для ретроаналитики/дообучения.
- Autoscaling: горизонтальное масштабирование model-serving под пиковую нагрузку, очередь запросов + priority for real-time streams.

SLA для latency: поддерживать p95 < 259 ms для *полного цикла* обработки одного user/API запроса (включая сетевые задержки). Для локальной inference latency целевого кадра должно быть < 100 ms.

Часть 3: Расчёты и нефункциональные требования

3.1 Входные данные и допущения

- DAU (пользователей в день): 1377775.
- Peak RPS: 5557 запросов в секунду.
- Target latency: ≤ 259 ms (полный ответ).
- Среднее число анализируемых событий на пользователя: 10 (подходящие «попадания»/позиции в сетке за посещение).
- Размер одного event-сообщения (json): 200 байт.
- Grid heatmap: 100 × 100 = 10000 ячеек на магазин.
- Агрегация: каждую минуту обновляется snapshot heatmap.
- Число магазинов в сети (assumption): 500 (если у вас другое число - масштабируйте линейно).

3.2 Расчёт требований к пропускной способности

1) Общее число событий в день:

- events_per_day = DAU × events_per_customer = 1377775 × 10 = 13777750 событий в день.

2) Суточный трафик (байты):

- bytes_per_day = events_per_day × 200 = 2755550000 байт ≈ 2.76 ГБ/день.

3) Пиковая одновременная нагрузка (конкурентность) при SLA:

- concurrency = RPS × latency(c)
  latency = 259 ms = 0.259 s
  concurrency = 5557 × 0.259 = 1439.263 одновременных запросов.

4) Число application instances (примерная оценка):

- Предположим один instance приложения выдерживает 200 одновременных соединений (workers/event loop).
- required_instances = ceil(1440 / 200) = 8 инстансов (горизонтальное автоскейлинг + запас - 1.5× для отказоустойчивости => deploy 12 инстансов).

5) Throughput model serving

- Если inference выполняется на GPU: допустим один GPU-node может обрабатывать 250 детекций в секунду (зависит от модели и батча).
- Для пиковой нагрузки 5557 inf/s потребуется ≈ 5557 / 250 = 23 GPU.
- Рекомендуемая конфигурация: старт 8 GPU для обычных часов + autoscale до 24 GPU на пик (spot/ondemand mix).

3.3 Расчёт требований к хранилищу

A. Хранение агрегированных тепловых карт (TSDB):

- Для одной сетки 100×100 = 10000 ячеек.
- Если сохраняем значение float64 (8 байт) => 10000 × 8 = 80000 байт ≈ 78.13 KB за snapshot.
- Частота snapshot: 1 минута => 1440 снапшотов в день => per_store/день = 78.13 KB × 1440 ≈ 112500 KB ≈ 110 MB/день/магазин.
- Для 500 магазинов => 110 MB × 500 = 55000 MB ≈ 53.7 ГБ/день.
- Ретеншен агрегатов (365 дней): 53.7 ГБ × 365 ≈ 19.6 TB.

B. Сохранение event-логов (json):

- событий в день (всего) = 13777750 => 2.76 ГБ/день.
- Для 30-дневного ретеншена ≈ 82.6 ГБ.

C. Object storage (анонимизированные кадры / мини-видео):

- Допущение: сохранение 1 кадра/5-сек для каждой камеры в сети для отладки.
- Пусть среднее число камер на магазин = 50 => кадры/sec per store = 50 / 5 = 10 кадров/sec => 864000 кадров/день/store.
- Размер уменьшенного анонимизированного кадра (jpeg low-res) ≈ 20 KB => per_store/день = 864000 × 20 KB = 17280000 KB ≈ 16.5 ГБ/день/магазин - это очень много; все кадры постоянно не хранятся.

Решение проектной архитектуры хранения видео:

- Хранить только агрегаты + events.
- Хранить анонимизированные кадры/мини-видео только при инциденте или последующем анализе.

- Если нужно кратковременное хранение - хранить 1% кадров или сохранить низкокачественные версии (2 KB), что сильно уменьшает объём.

3.4 Масштабируемость и надёжность

Архитектурные решения для масштабируемости:

- Stream Broker (Kafka) с несколькими partition per store/camera для горизонтального масштабирования.
- Stateless microservices (inference API, API Gateway) с горизонтальным autoscaling (Kubernetes + HPA/VPA).
- Stateful components (TSDB, DB) - кластерный режим (TimescaleDB/InfluxDB × Replication).
- Model serving: Triton/TF-Serving с GPU pool + autoscale; fallback на CPU-light model версия при перегрузке.

Надёжность и отказоустойчивость:

- Deploy в мультизональной инфраструктуре (AZs).
- Репликация критичных сервисов (Kafka zookeeper, controller, DB replicas).
- Circuit breakers и retry policy между микросервисами.
- Canary deploy + automatic rollback при деградации качества (mAP/p95 latency thresholds).

3.5 Приватность и безопасность

- Face-blurring выполняется на edge либо сразу при приёме видеопотока в cloud - гарантируем 100% размытия лиц перед сохранением.
- Данные трекинга хранятся без пикселей/кропов лиц (координаты и хеши ID).
- Аудит и верификация: периодические проверки (privacy auditor) - выборочная проверка кадра/логов.
- Шифрование: TLS для потоков, серверное шифрование S3 (SSE).
- Ретеншен: минимальный срок хранения персональных данных (по нормативам 7–30 дней) и возможность удаления по запросу.

3.6 Диаграмма

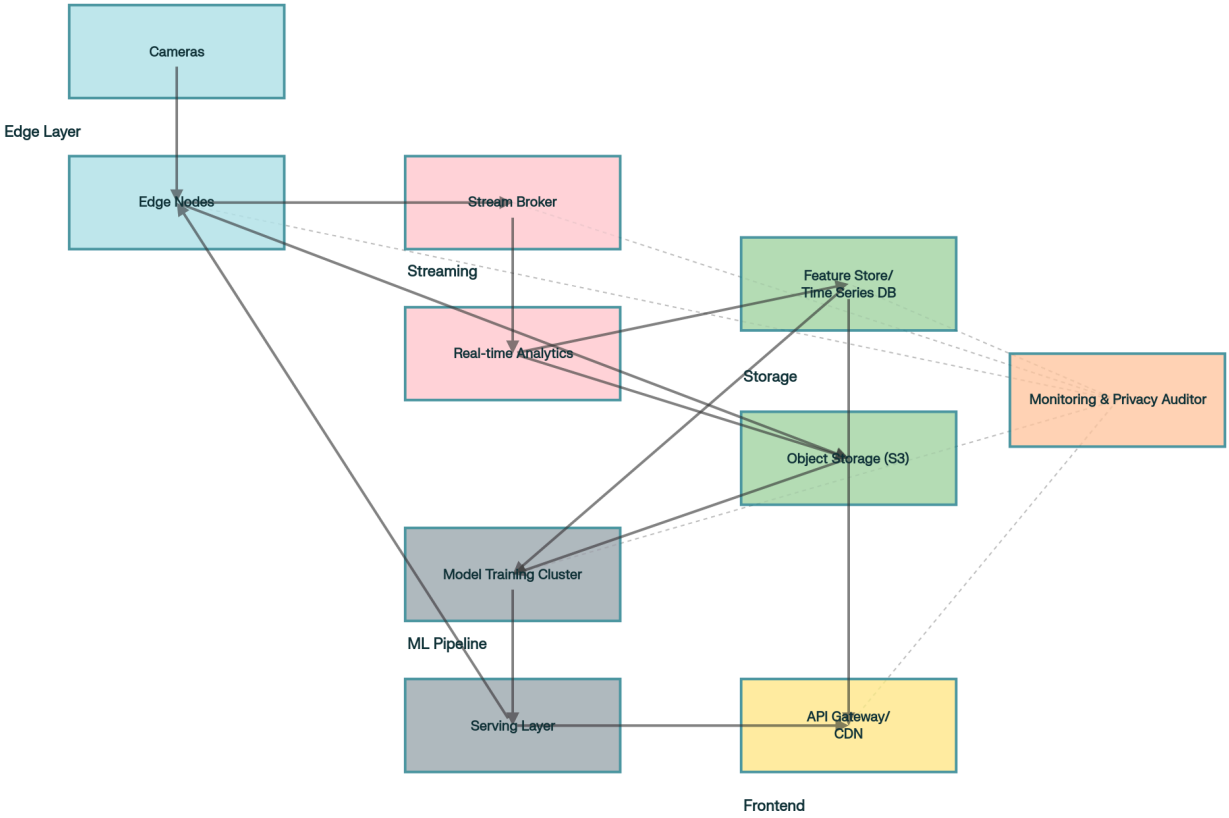

Список источников

1. Redmon J., Farhadi A., "YOLO: Real-Time Object Detection"
2. Wojke, Bewley & Paulus, "Simple Online and Realtime Tracking with a Deep Association Metric"
3. Ramon, et al., "FairMOT: On the Fairness of Detection and Re-Identification in Multi-Object Tracking"
4. Документация Kafka
5. Документация Apache Flink
6. Документация TimescaleDB
7. Документация Prometheus